Universidad Rafael Landivar
Facultad de ingeniería

Ciencia de Datos

Ing. Max Cerna

Fase 2 Proyecto 2

José Rodrigo Rosales Mirón – 1143323

Paula Ximena Navarro Ruano – 1006323

Eddy Paolo Marroquín Montenegro - 1146822

Guatemala, 11 de noviembre de 2026

Documentación de evidencias | Fase 2

Proyecto 2 - Ciencia de Datos · Red Metropolitana de Transporte

Este documento reúne las 20 imágenes entregadas de los apartados 2.1 a 2.4. Cada evidencia incluye una explicación de su alcance. El diseño conserva la organización visual de la documentación de la Fase 1.

Resultados principales

2.1 Modelos e interpretación	3 evidencias: comparación, sesgo-varianza e importancia
2.2 Política y test B	6 evidencias: umbral 1/3 y evaluación externa única
2.3 Segmentación KMeans	5 evidencias: seis perfiles, PCA 57.68% de varianza
2.4 MLOps	6 evidencias: pipeline A, SHA256 y 49 pruebas sintéticas

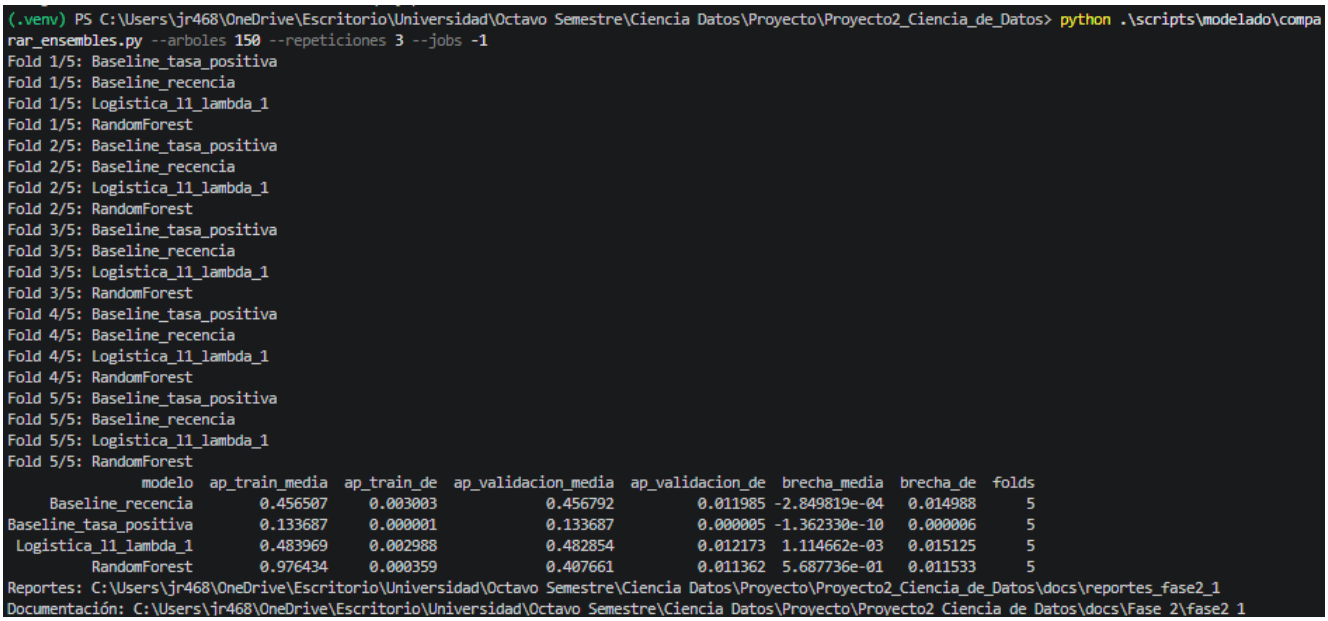
Alcance y límites: las evidencias de MLOps acreditan persistencia, integridad y pruebas sintéticas. No acreditan la generación de predicciones reales para el corte C ni la invariancia con fuentes reales. El adaptador mantiene bloqueos por falta de historia verificable de identidad y disponibilidad.

2.1 - Comparación de modelos e interpretabilidad

Se estudió el comportamiento de los modelos y la relación entre sesgo, varianza e importancia de las variables, a partir de los resultados de la fase de modelado.

Evidencia 01. Comparación de modelos

Presenta la comparación de desempeño de los modelos considerados para el problema de abandono.

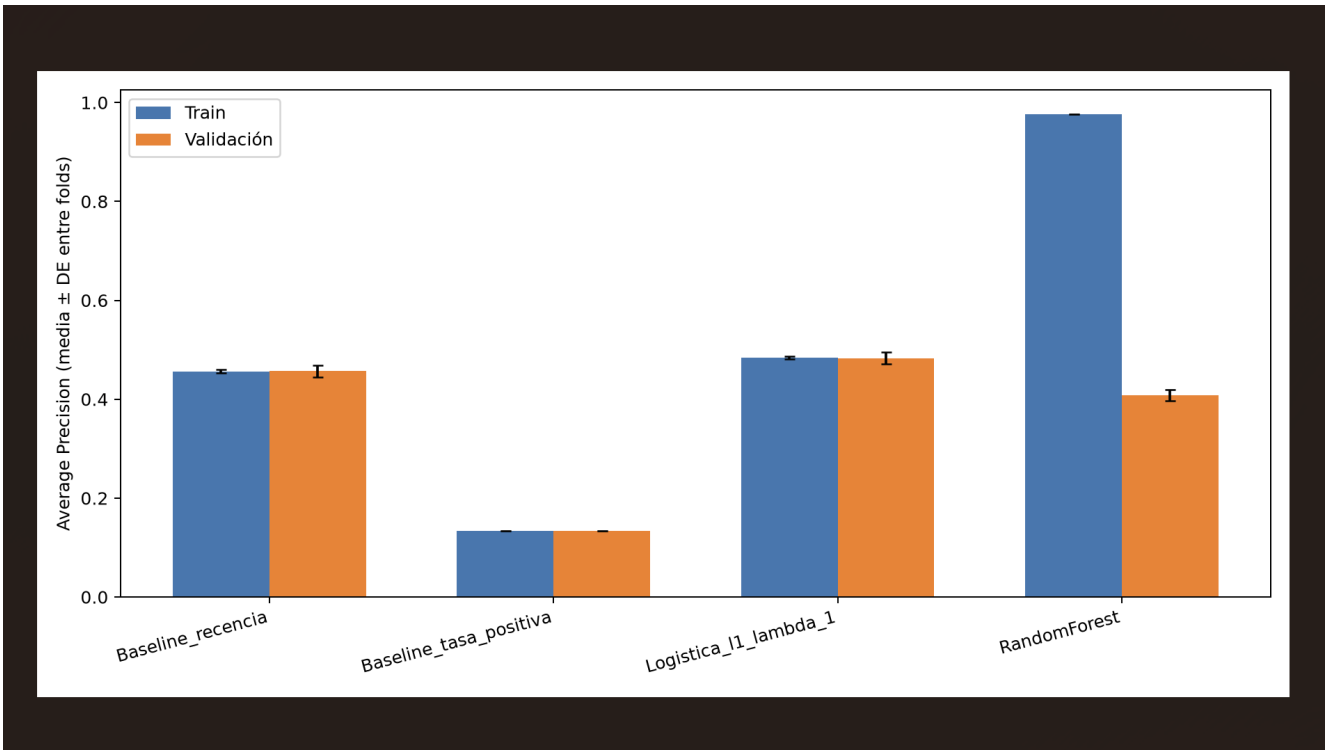


```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos> python .\scripts\modelado\compa
rar_ensembles.py --arboles 150 --repeticiones 3 --jobs -1
Fold 1/5: Baseline_tasa_positiva
Fold 1/5: Baseline_recencia
Fold 1/5: Logistica_11_lambda_1
Fold 1/5: RandomForest
Fold 2/5: Baseline_tasa_positiva
Fold 2/5: Baseline_recencia
Fold 2/5: Logistica_11_lambda_1
Fold 2/5: RandomForest
Fold 3/5: Baseline_tasa_positiva
Fold 3/5: Baseline_recencia
Fold 3/5: Logistica_11_lambda_1
Fold 3/5: RandomForest
Fold 4/5: Baseline_tasa_positiva
Fold 4/5: Baseline_recencia
Fold 4/5: Logistica_11_lambda_1
Fold 4/5: RandomForest
Fold 5/5: Baseline_tasa_positiva
Fold 5/5: Baseline_recencia
Fold 5/5: Logistica_11_lambda_1
Fold 5/5: RandomForest
              modelo  ap_train_media  ap_train_de  ap_validacion_media  ap_validacion_de  brecha_media  brecha_de  folds
     Baseline_recencia        0.456507     0.003003             0.456792          0.011985 -2.849819e-04   0.014988      5
Baseline_tasa_positiva        0.133687     0.000001             0.133687          0.000005 -1.362330e-10   0.000006      5
 Logistica_11_lambda_1        0.483969     0.002988             0.482854          0.012173  1.114662e-03   0.015125      5
          RandomForest        0.976434     0.000359             0.407661          0.011362  5.687736e-01   0.011533      5
Reportes: C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos\docs\reportes_fase2_1
Documentación: C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos\docs\Fase 2\fase2_1
```

Fuente: evidencia de ejecución del Proyecto 2 · 01_comparacion_modelos.png

Evidencia 02. Análisis de sesgo y varianza

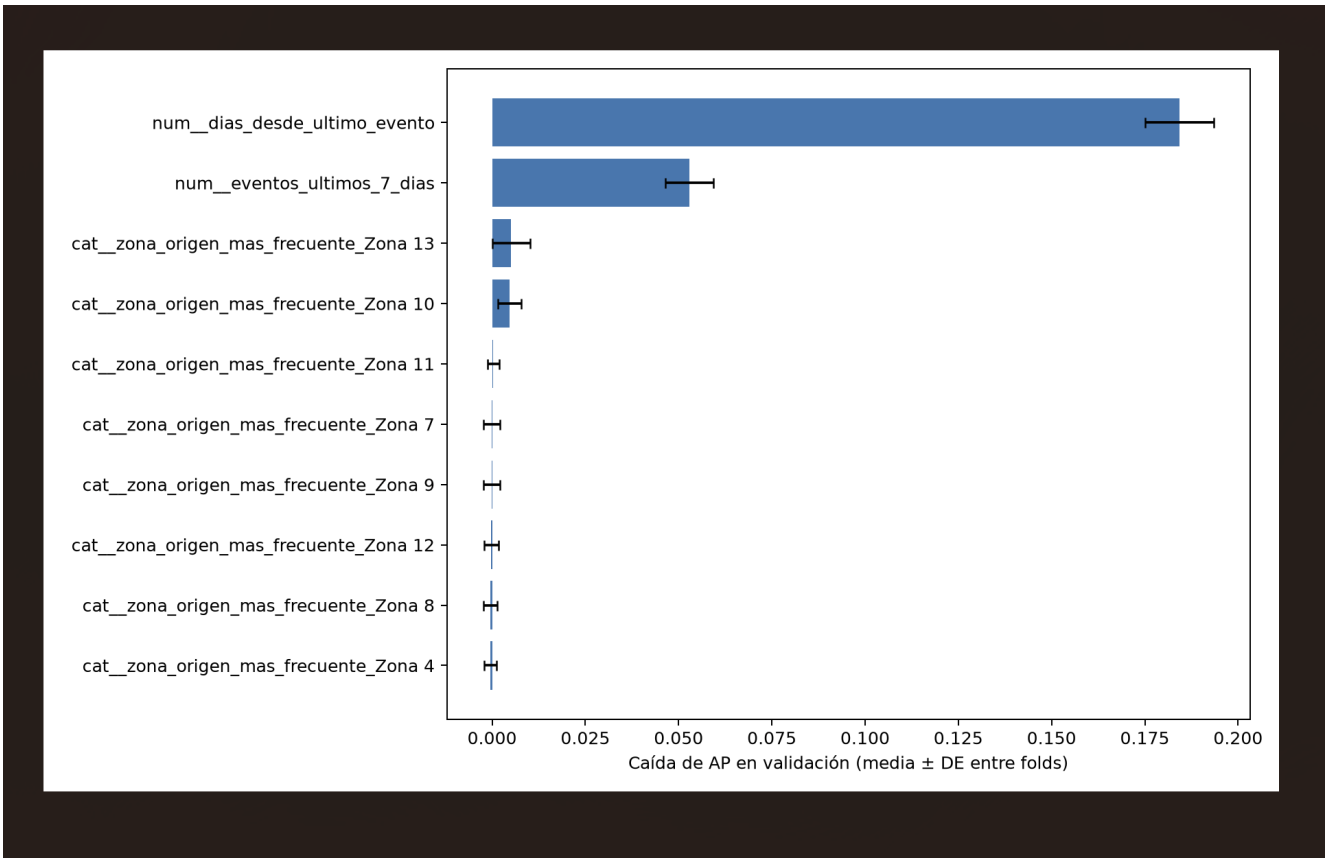
Ilustra el análisis de sesgo y varianza y sus implicaciones sobre el ajuste y la generalización.



Fuente: evidencia de ejecución del Proyecto 2 · 02_sesgo_varianza.png

Evidencia 03. Importancia por permutación

Muestra la estimación de importancia de las características mediante permutación, como apoyo a la interpretación.



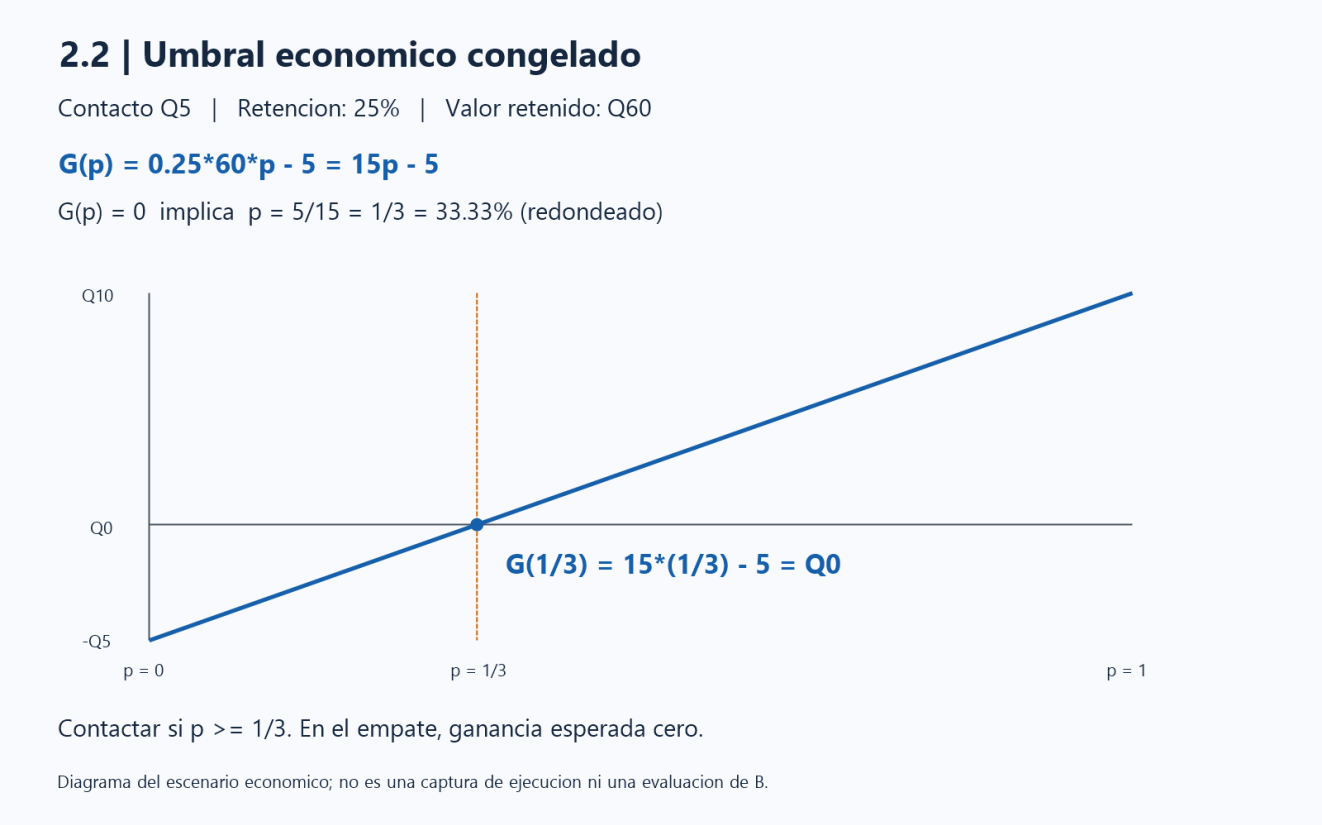
Fuente: evidencia de ejecución del Proyecto 2 · 03_importancia_permutacion.png

2.2 - Política de contacto y evaluación única B

Se estableció una política de contacto con umbral económico congelado y se documentó la evaluación externa única del corte B, sin repetirla ni modificar posteriormente la decisión.

Evidencia 01. Cálculo del umbral económico

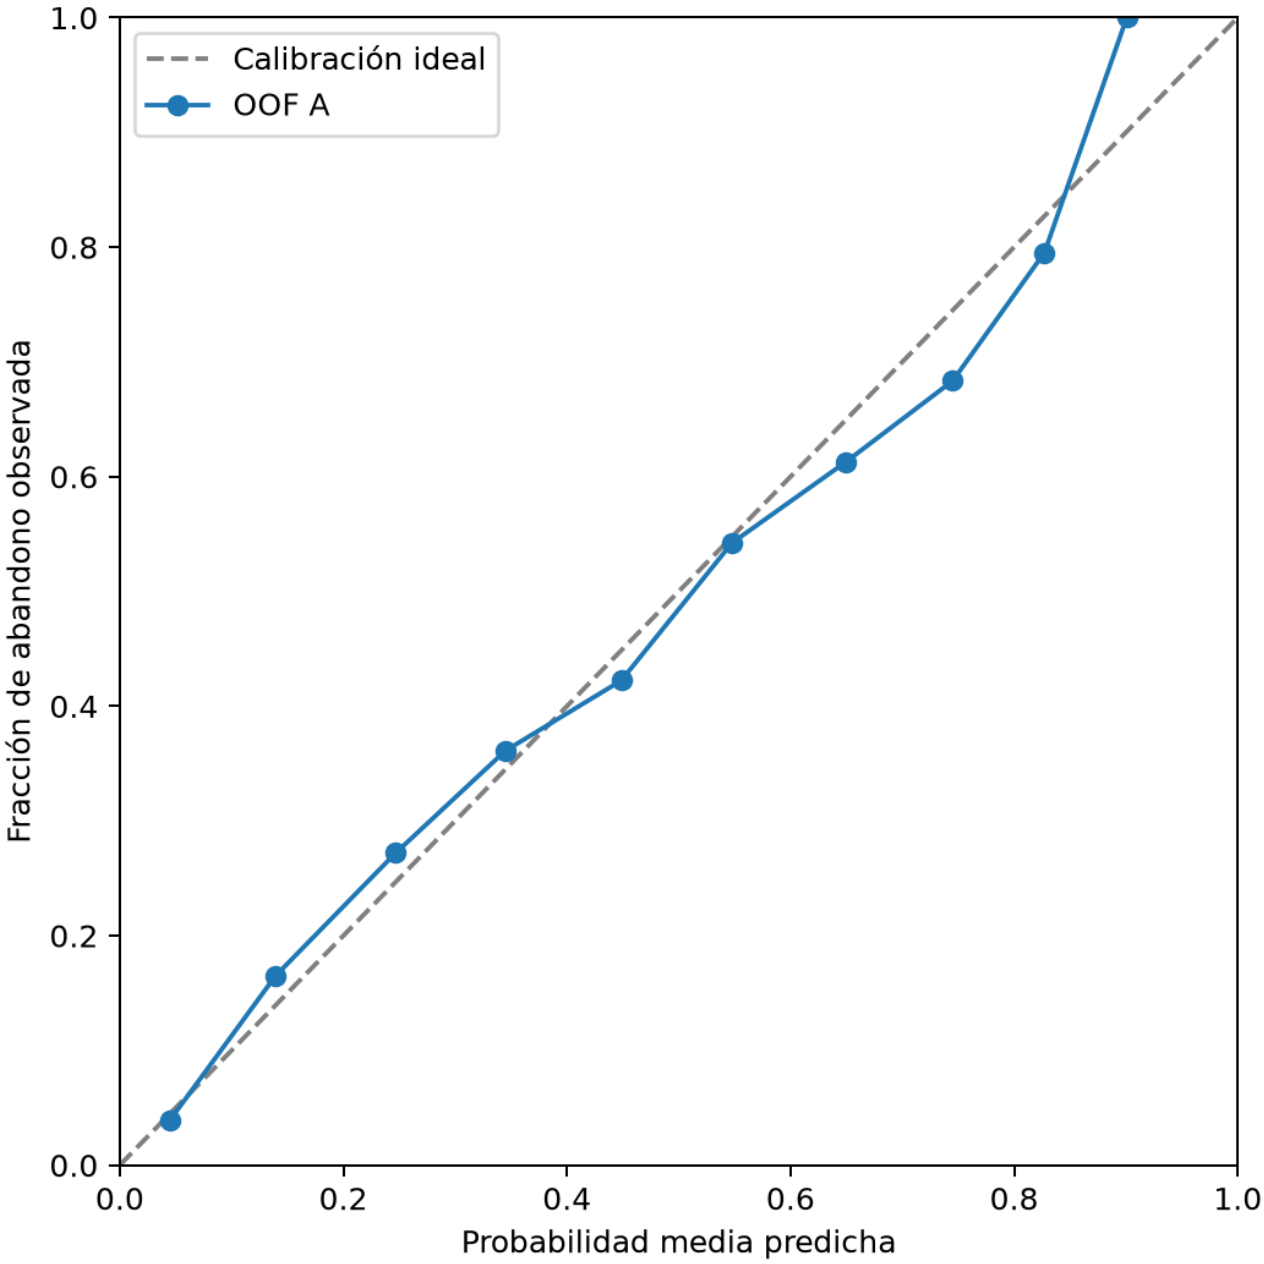
Documenta el cálculo que determinó el umbral de contacto fijado en un tercio.



Fuente: evidencia de ejecución del Proyecto 2 · 01_calculo_umbral.png

Evidencia 02. Calibración fuera de muestra en A

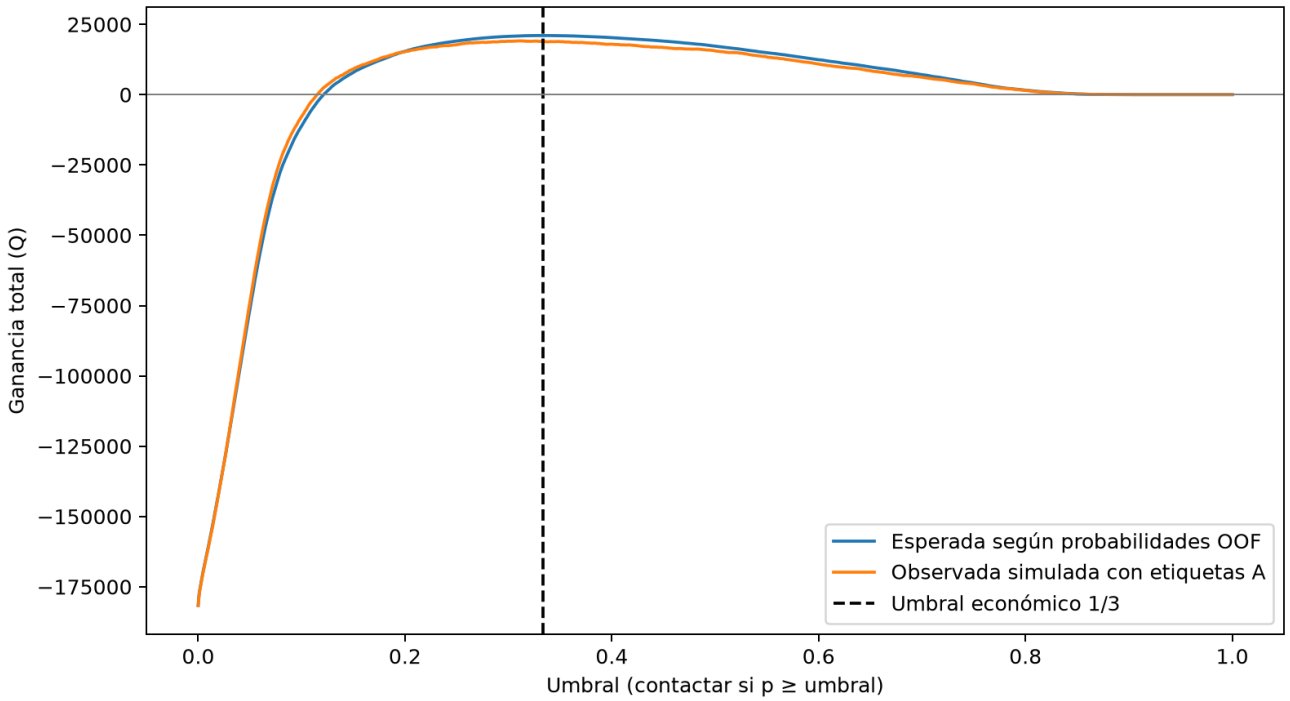
Presenta la evidencia de calibración sobre predicciones fuera de fold (OOF) del corte A.



Fuente: evidencia de ejecución del Proyecto 2 · 02_calibracion_oof.png

Evidencia 03. Curva de ganancia

Visualiza la ganancia estimada bajo el escenario económico utilizado en la política de contacto.



Fuente: evidencia de ejecución del Proyecto 2 · 03_curva_ganancia.png

Evidencia 04. Evaluación única del corte B

Registra la evaluación externa realizada una sola vez sobre B, con el modelo y la política ya definidos.

2.2 | Evaluación única B — resultado registrado

TEST FINAL CONSUMIDO | L1 C=1 | Umbral fijo: p >= 1/3

B: evaluación final. A: selección y validación cruzada previas.

Indicador	Resultado B
Total evaluado	59126
Average precision (AP)	0.440916
Precisión	0.488829
Recall	0.427902
ROC-AUC	0.847482
Brier	0.085068
Log-loss	0.281870

Fecha del resultado UTC: 2026-11-11T20:32:33.828262+00:00

FINALIZADO UTC: 2026-11-11T20:32:33.890840+00:00

Commit de ejecución: 931146e26c0dec88ec374bd2b8015c185fdaf90f

Snapshot limitado: certificado_origen=false. No acredita completitud independiente.

Lámina documental desde agregados existentes; no es una nueva ejecución ni validación A.

Fuente: resultado_test_b.agregado.json y cierre_fase2_2.md. No repetir ni reajustar.

Fuente: evidencia de ejecución del Proyecto 2 · 04_evaluacion_unica_b.png

Evidencia 05. Matriz de confusión y ganancia en B

Resume los resultados agregados de clasificación y del escenario económico de contacto del corte B.

2.2 | B único — matriz y ganancia simulada

Resultado agregado del test final B; no corresponde a validación OOF A.

Real / decisión	Contactar	No contactar
Positivo	**TP = 3107**	**FN = 4154**
Negativo	**FP = 3249**	**TN = 48616**

Q5 por contacto | 25% retención condicional | Q60 por retenido

G = 0.25 × 60 × TP − 5 × (TP + FP)

= 10 × TP − 5 × FP

= 10 × 3107 − 5 × 3249 = Q14,825.00

Ganancia observada SIMULADA: no es beneficio causal ni retención realizada.

Evaluación: 2026-11-11 UTC | FINALIZADO: 20:32:33.890840 UTC

Commit de ejecución: 931146e26c0dec88ec374bd2b8015c185fdaf90f

Snapshot limitado: certificado_origen=false; etiquetas de actividad registrada.

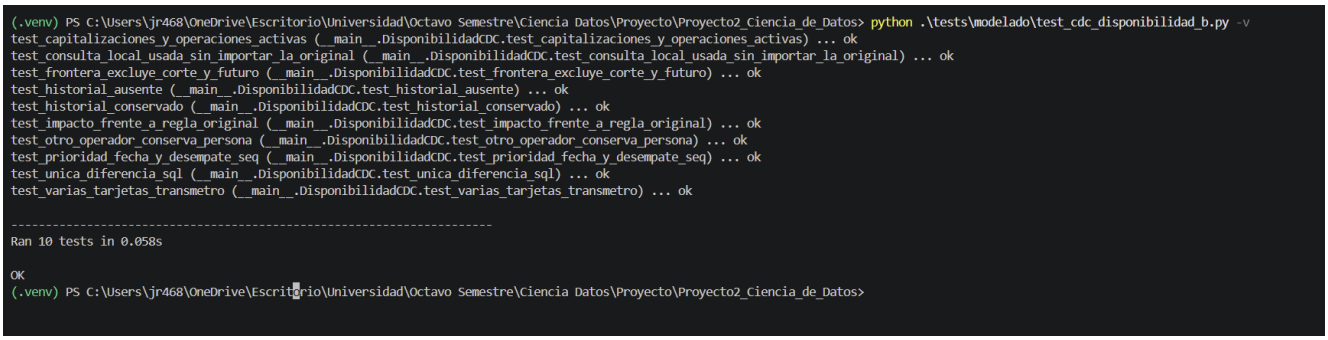
Fuente: resultado_test_b.agregado.json y cierre_fase2_2.md. Solo agregados existentes.

Lámina documental; no se leyó el CSV B. Test consumido: no repetir ni reajustar.

Fuente: evidencia de ejecución del Proyecto 2 · 05_matriz_confusion_ganancia_b.png

Evidencia 06. Pruebas de reglas CDC

Evidencia las comprobaciones asociadas a reglas CDC y su tratamiento en el proceso.



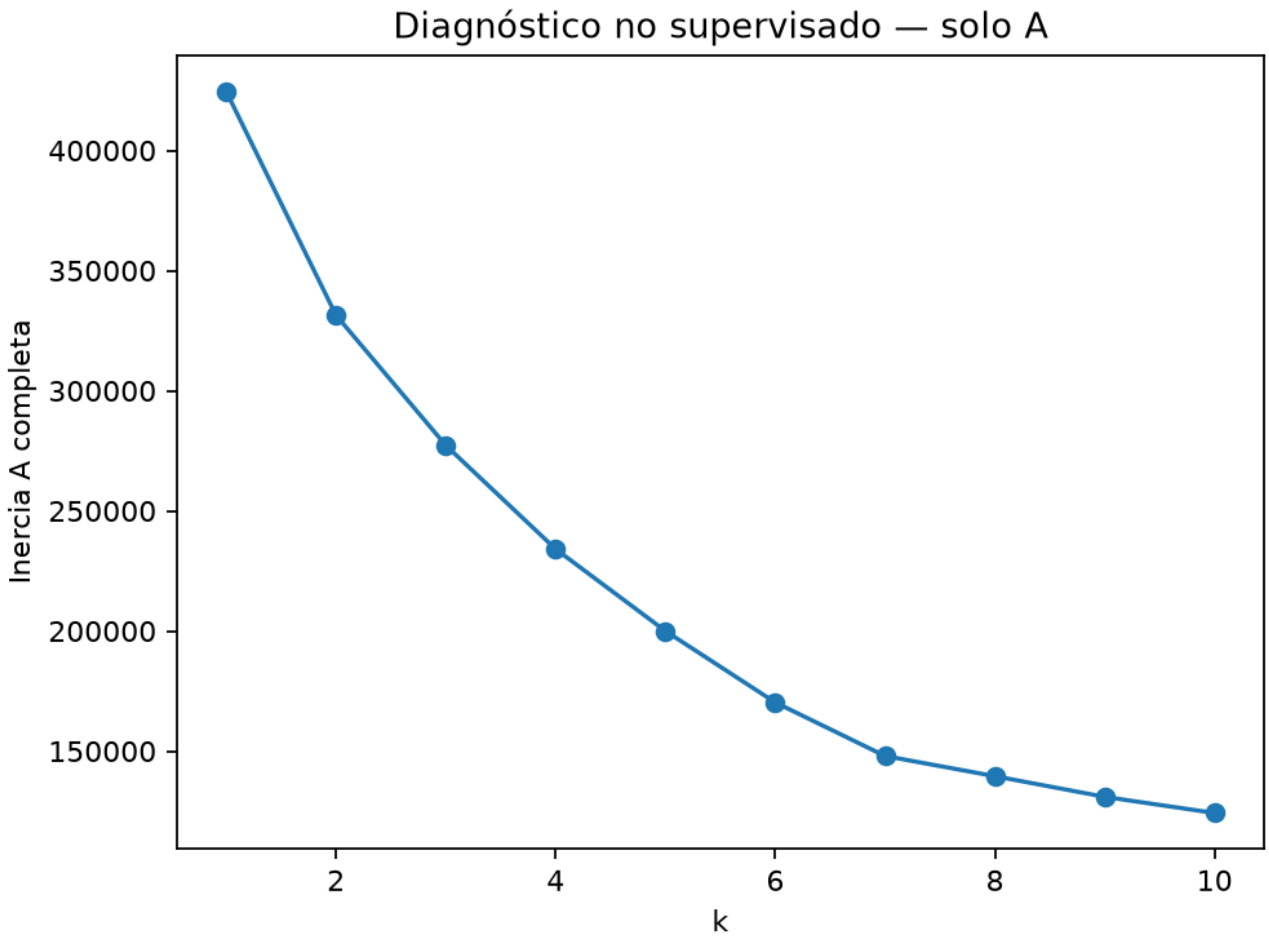
Fuente: evidencia de ejecución del Proyecto 2 · 06_pruebas_cdc.png

2.3 - Segmentación KMeans y visualización PCA

Se agruparon 60,664 usuarios del corte A mediante variables escaladas. La selección final de seis segmentos equilibró codo, silueta, representatividad e interpretación sin utilizar abandono para elegir k.

Evidencia 01. Diagnóstico del método del codo

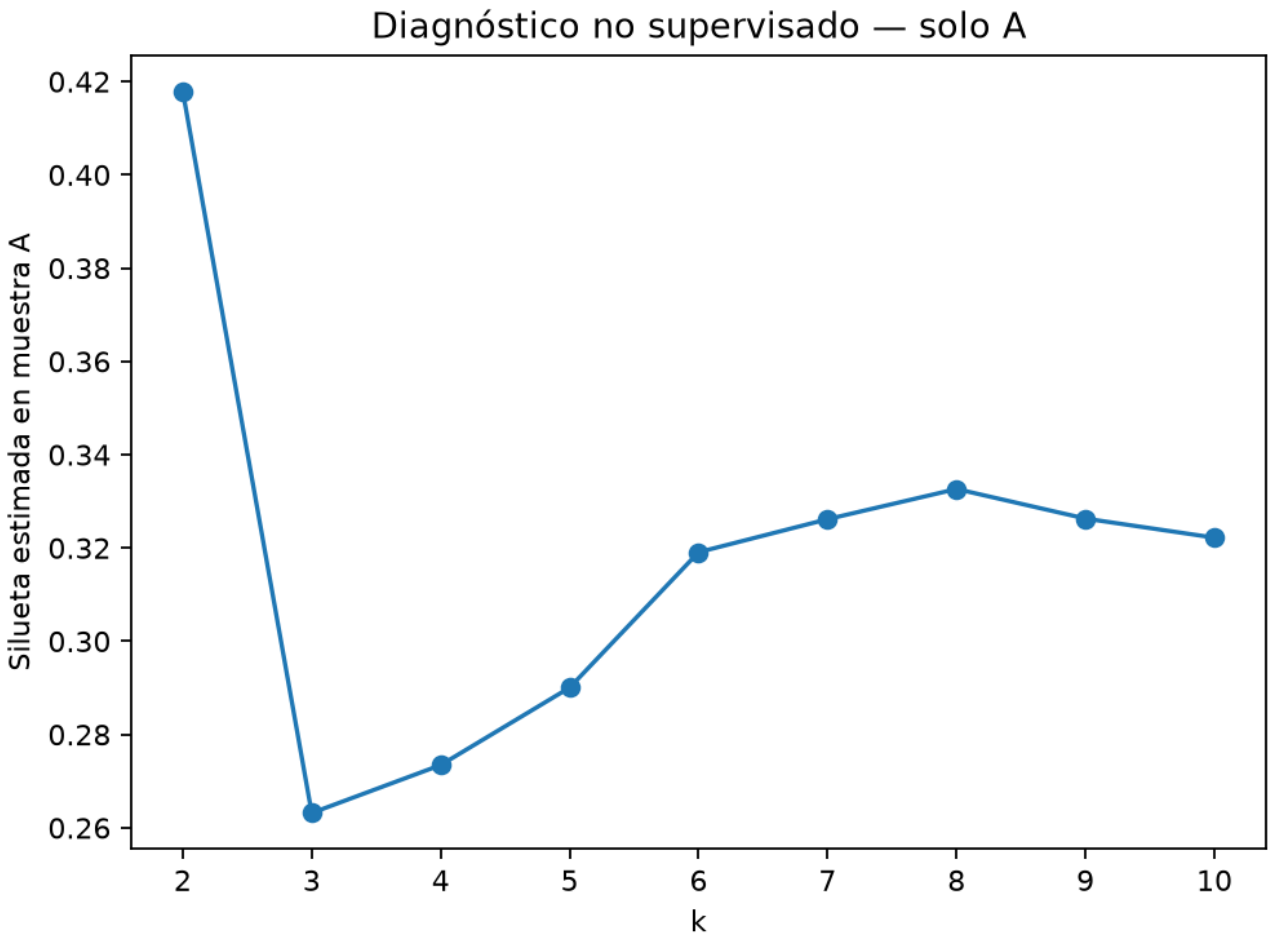
Muestra la inercia para los valores candidatos de k usados para apoyar la selección del número de grupos.



Fuente: evidencia de ejecución del Proyecto 2 · 01_codo.png

Evidencia 02. Diagnóstico de silueta

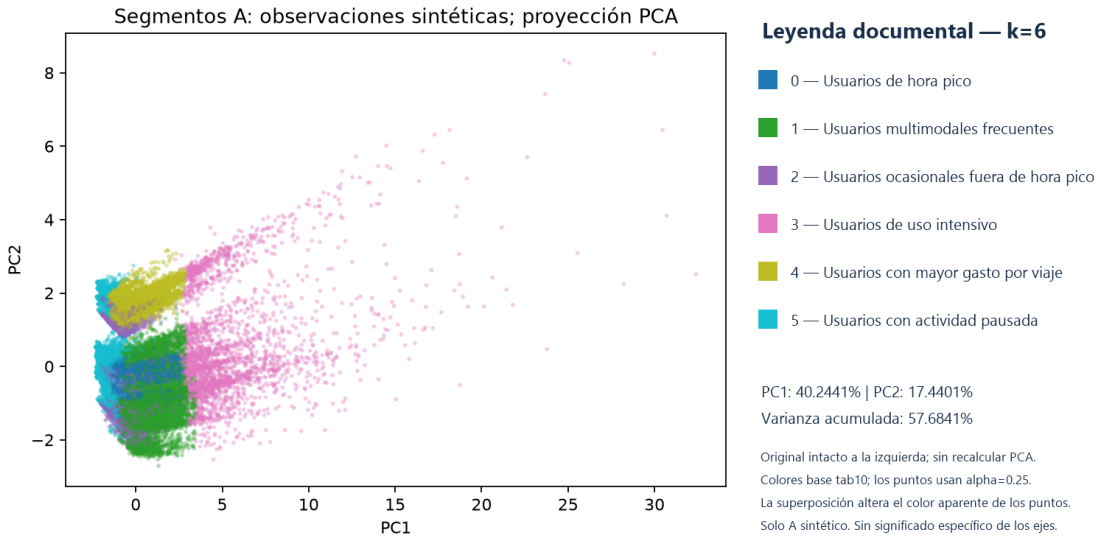
Presenta la calidad de separación de los candidatos de agrupamiento mediante silueta muestral.



Fuente: evidencia de ejecución del Proyecto 2 · 02_silueta.png

Evidencia 03. PCA de dos componentes, con leyenda

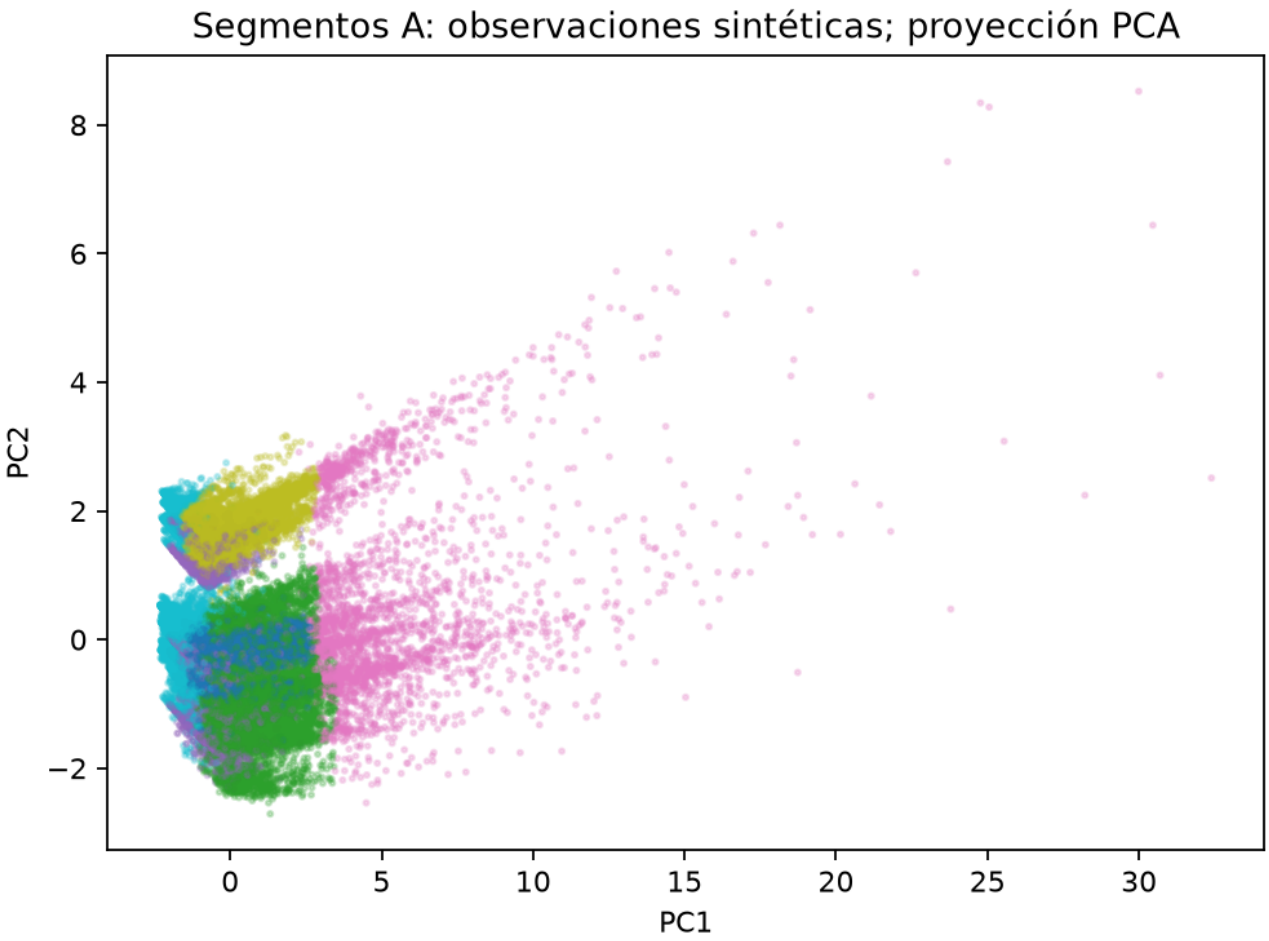
Representa los seis segmentos sobre dos componentes principales e identifica sus colores con una leyenda.



Fuente: evidencia de ejecución del Proyecto 2 · 03_pca_2d.con_leyenda.png

Evidencia 04. PCA de dos componentes, versión original

Conserva la gráfica original del PCA, sin modificaciones en el área de dispersión.



Fuente: evidencia de ejecución del Proyecto 2 · 03_pca_2d.original.png

Evidencia 05. Perfiles de segmentos y acciones

Resume los seis perfiles y sus acciones de retención diferenciadas a partir de estadísticas descriptivas.



Fuente: evidencia de ejecución del Proyecto 2 · 04_perfiles_y_acciones.png

2.4 - MLOps y reproducibilidad

Se implementó y publicó el código de persistencia e inferencia; el pipeline de A fue reproducido y se verificó su integridad. Las pruebas sintéticas están aprobadas. La generación real del corte C y su invariancia sobre fuentes históricas siguen pendientes.

Evidencia 01. Pipeline persistido

Muestra los archivos del modelo reproducido sobre A, su manifiesto y el marcador FINALIZADO.

```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos> Get-ChildItem modelos/fase2_4 |
>>     Where-Object { $_.Name -notlike "*.partial" } |
>>     Select-Object Name, Length

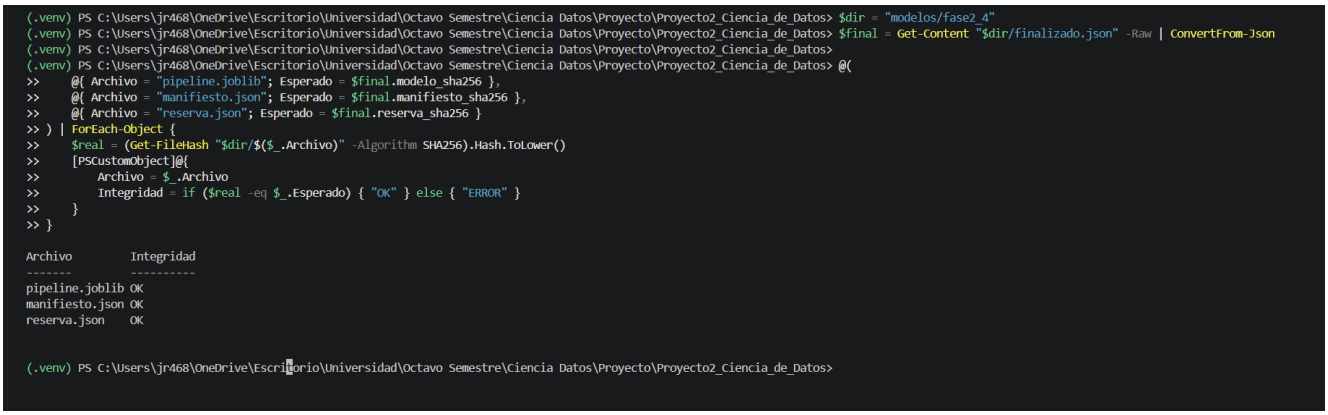
Name            Length
----            ------
finalizado.json    425
manifiesto.json   8116
pipeline.joblib   2421
reserva.json      1288


(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos>
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos> Get-Content modelos/fase2_4/finalizado.json
{
  "version": 2,
  "estado": "FINALIZADO",
  "fecha_utc": "2026-11-12T01:44:33.980237+00:00",
  "modelo_sha256": "f0fef06ff12939bcd5d8dd18bd09d2caa86a37d3b0546c7f387583d8cb94d057",
  "manifiesto_sha256": "c6634c65d2641f996ac0609804964817c86938534cdeaa69dbb78efd97c2ff4f",
  "reserva_sha256": "e9d2839e21c6c808f310931d91c954ad067f5abc0a82a761fdbef46777e6b879",
  "commit": "54a33fa98c6830fbe85cbd1b9eb7c9065429b247"
}
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos>
```

Fuente: evidencia de ejecución del Proyecto 2 · 01_pipeline_persistido.png

Evidencia 02. Comprobación SHA256

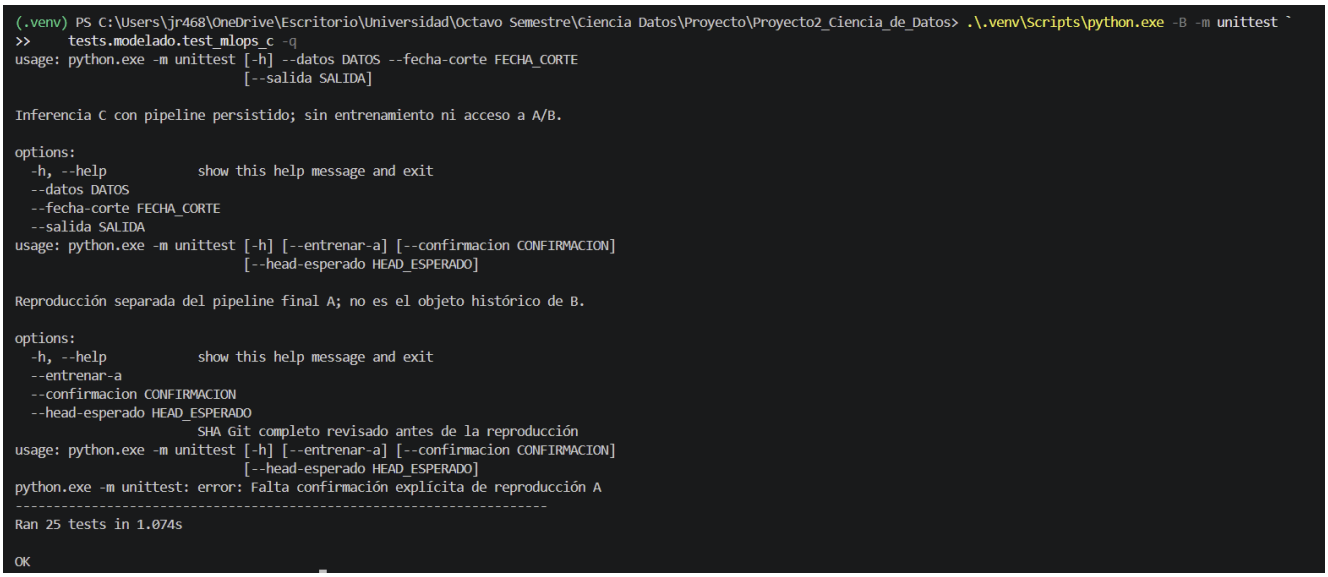
Verifica que pipeline, manifiesto y reserva coinciden con los hashes declarados al finalizar.



Fuente: evidencia de ejecución del Proyecto 2 · 02_integridad_sha256.png

Evidencia 03. Pruebas sintéticas MLOps

Registra la ejecución satisfactoria de las 25 pruebas sintéticas del contrato y de la inferencia.



```
(.venv) PS C:\Users\jr468\OneDrive\Escritorio\Universidad\Octavo Semestre\Ciencia Datos\Proyecto\Proyecto2_Ciencia_de_Datos> .\.venv\Scripts\python.exe -B -m unittest `
>>     tests.modelado.test_mlops_c -q
usage: python.exe -m unittest [-h] --datos DATOS --fecha-corte FECHA_CORTE
                              [--salida SALIDA]

Inferencia C con pipeline persistido; sin entrenamiento ni acceso a A/B.

options:
  -h, --help            show this help message and exit
  --datos DATOS
  --fecha-corte FECHA_CORTE
  --salida SALIDA
usage: python.exe -m unittest [-h] [--entrenar-a] [--confirmacion CONFIRMACION]
                              [--head-esperado HEAD_ESPERADO]

Reproducción separada del pipeline final A; no es el objeto histórico de B.

options:
  -h, --help            show this help message and exit
  --entrenar-a
  --confirmacion CONFIRMACION
  --head-esperado HEAD_ESPERADO
                        SHA Git completo revisado antes de la reproducción
usage: python.exe -m unittest [-h] [--entrenar-a] [--confirmacion CONFIRMACION]
                              [--head-esperado HEAD_ESPERADO]
python.exe -m unittest: error: Falta confirmación explícita de reproducción A
----------------------------------------------------------------------
Ran 25 tests in 1.074s

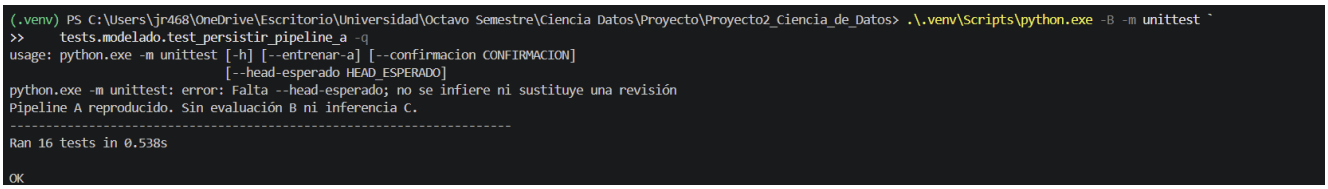
OK
```

Fuente: evidencia de ejecución del Proyecto 2 · 03_pruebas_mlops.png

Prueba sintética: no acredita resultados reales del corte C.

Evidencia 04. Pruebas de persistencia

Registra 16 pruebas de integridad del guardado con objetos simulados, sin reentrenamiento real.

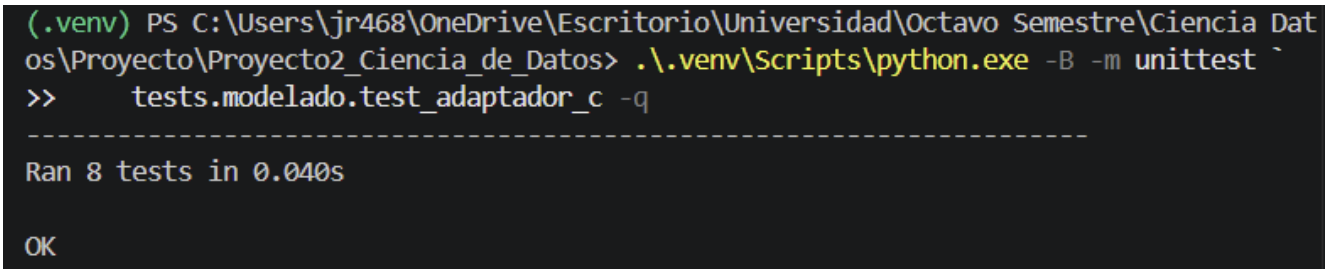


Fuente: evidencia de ejecución del Proyecto 2 · 04_pruebas_persistencia.png

Prueba sintética: no acredita resultados reales del corte C.

Evidencia 05. Pruebas del adaptador

Registra ocho pruebas del adaptador de fuentes con entradas sintéticas y bloqueos de procedencia.

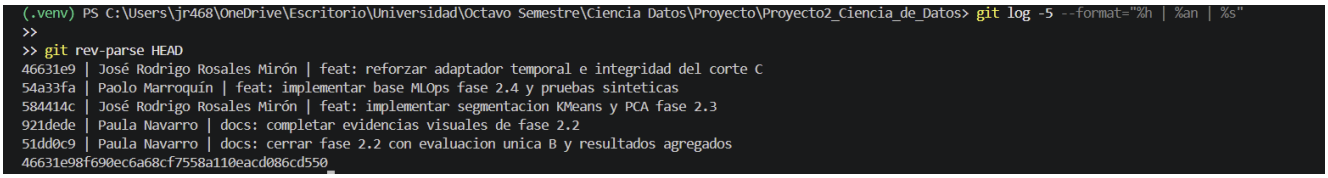


Fuente: evidencia de ejecución del Proyecto 2 · 05_pruebas_adaptador.png

Prueba sintética: no acredita resultados reales del corte C.

Evidencia 06. Commits de MLOps

Presenta la trazabilidad del código publicado, incluidas la implementación inicial y las validaciones temporales.



Fuente: evidencia de ejecución del Proyecto 2 · 06_commits_mlops.png

Conclusión general

La Fase 2 amplía el proyecto mediante la comparación e interpretación de modelos, la definición de una política de contacto, la segmentación de usuarios y la implementación de mecanismos de reproducibilidad e inferencia.

En 2.2 se conservó una única evaluación externa del corte B. En 2.3 se identificaron seis segmentos sobre 60,664 registros de A; el PCA de dos componentes explica aproximadamente 57.68% de la variación. En 2.4 se reprodujo el pipeline a partir de A y se verificaron los hashes de pipeline, manifiesto y reserva. Las 49 pruebas sintéticas reportadas (25 MLOps, 16 persistencia y 8 adaptador) finalizaron satisfactoriamente.

Limitación abierta: no se ha acreditado la disponibilidad histórica y la identidad point-in-time necesarias para producir y verificar las predicciones del corte C del 30 de agosto de 2026. Por ello, ni la inferencia C real ni la invariancia con fuentes reales se presentan como completadas. El binario del modelo permanece bajo revisión de privacidad antes de su publicación.